Diagnóstico Inicial da Base de Dados

Componente	Projeto Profissional de Análise de Dados
Unidade	Unidade 2 — Coleta, organização e preparação dos dados
Projeto-base	Login System → Dashboard de Análise de Dados
Equipe	Jacob Almeida, Carlos Henrique, Junio e Jhullyana
Data	08/10/2026

1. Identificação

Nome do projeto	Login System Analytics (Login System → Dashboard de Análise de Dados)
Integrantes	Jacob Almeida, Carlos Henrique, Junio e Jhullyana
Tema	Oferta de cursos e matrículas nas Escolas do Futuro de Goiás. [conferir com a Aula 1]
Problema	[copiar o problema definido na Aula 1]
Pergunta principal	Como evoluíram a oferta de turmas e as matrículas nas Escolas do Futuro entre 2022 e 2026, e quais escolas e cursos concentram maior procura e melhor preenchimento das vagas? [conferir com a Aula 2]

2. Fonte

Instituição responsável	Secretaria de Estado de Ciência, Tecnologia e Inovação de Goiás (SECTI-GO), por meio da Gerência de Tecnologia. Dados do Sistema de Gerenciamento Acadêmico das Escolas do Futuro (SIGA).
Nome da base	Turmas das Escolas do Futuro - SECTI
Link	https://dadosabertos.go.gov.br/dataset/turmas-escolas-do-futuro

Período	1º semestre de 2022 a 1º semestre de 2026 (9 arquivos CSV semestrais, de turmasefg_202201.csv a turmasefg_202601.csv).
Data de acesso	08/10/2026
Descrição	Informações sobre as turmas em execução nas Escolas do Futuro de Goiás. Publicada no Portal de Dados Abertos do Estado de Goiás em 03/06/2025, com atualização em 08/10/2026, frequência anual, versão 1.0 e licença Creative Commons Atribuição (CC-BY).

3. Estrutura

Formato do arquivo	CSV, com campos entre aspas duplas, ponto e vírgula (;) como separador e marcador BOM no início (leitura com encoding utf-8-sig).
Quantidade de registros	[dados.shape, primeiro número, do arquivo turmasefg_202601.csv] (cada registro é uma turma)
Quantidade de colunas	15
Arquivo de referência	turmasefg_202601.csv (1º semestre de 2026), com os demais arquivos seguindo a mesma estrutura [confirmar no Colab]

Descrição das principais colunas

O dicionário oficial descreve apenas 4 das 15 colunas (status_turma, carga_horaria, matriculas_turma e matriculas_aptas) e só repete o nome do campo. O significado das demais foi interpretado pela equipe a partir dos nomes e dos valores observados.

Coluna	Significado	Tipo esperado	Será usada?
id_turma	Identificador numérico da turma.	Inteiro	Sim (chave)
turma	Código da turma (ex.: QP-JLB-ACCN-I1-2026), que reúne categoria, escola, curso, turno/modalidade e ano.	Texto	Talvez

escola	Unidade das Escolas do Futuro em que a turma funciona.	Texto	Sim
projeto	Programa ou projeto ao qual a turma pertence.	Texto	Talvez
categoria	Tipo de oferta (ex.: capacitação ou qualificação profissional).	Texto	Sim
curso	Nome do curso ofertado.	Texto	Sim
modalidade	Forma de oferta da turma (ex.: presencial ou on-line).	Texto	Sim
qtde_vagas	Quantidade de vagas ofertadas na turma.	Inteiro	Sim
turno	Turno em que a turma funciona.	Texto	Sim
data_inicio	Data de início da turma.	Data	Sim
data_fim	Data de término da turma.	Data	Sim
status_turma	Situação da turma (ex.: Não Iniciado, Concluído).	Texto	Sim
carga_horaria	Carga horária do curso, em horas.	Inteiro	Talvez
matriculas_turma	Quantidade de matrículas na turma.	Inteiro	Sim
matriculas_aptas	Quantidade de matrículas consideradas aptas; o dicionário oficial não explica o critério.	Inteiro (vem com “-” em turmas sem dado)	Sim, com cuidado

4. Qualidade inicial

Nesta aula apenas identificamos os problemas. Nenhum valor foi alterado, preenchido ou excluído, e a base original será guardada sem alterações na pasta data.

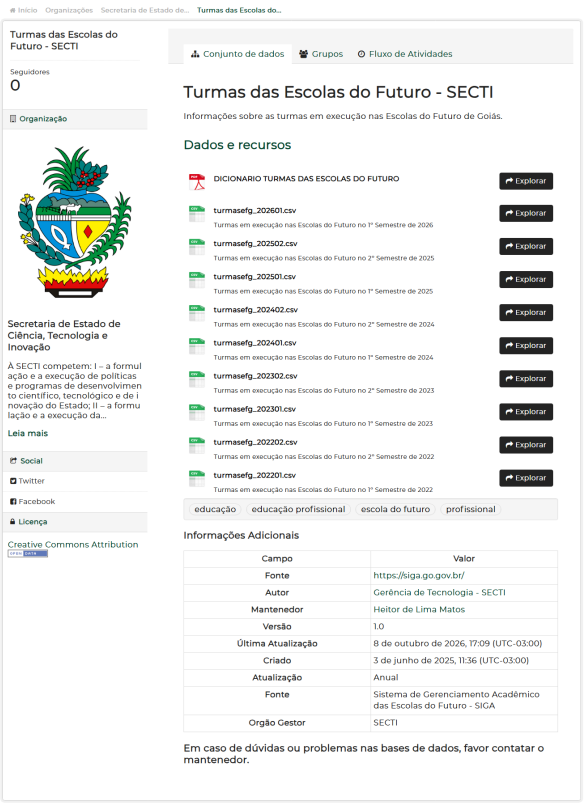
Valores ausentes	A coluna matriculas_aptas traz o sinal “-” nas turmas ainda não iniciadas (ex.: turmas 8877 e 8874), ou seja, não há número. Demais colunas: [dados.isnull().sum()]
Possíveis duplicidades	[dados.duplicated().sum() e dados["id_turma"].duplicated().sum()]
Inconsistências	[variações de escrita nos nomes de escola, curso, modalidade e turno, após conferir os valores únicos]
Problemas de padronização	1) O dicionário usa nomes de campos em maiúsculas (STATUS_TURMA) e o CSV em minúsculas (status_turma). 2) Por causa do “-”, matriculas_aptas pode ser lida como texto e não como número. 3) A base está dividida em 9 arquivos semestrais, que precisarão ser conferidos e reunidos.
Observações	O dicionário é incompleto: não explica o critério de “matrículas aptas” nem descreve a maioria das colunas. Os ids de turma têm lacunas, o que é esperado em uma base de turmas em execução. A base é de turmas, e não de alunos, então não permite análises individuais ou de evasão.

5. Relação com o projeto

Pergunta	Dados necessários	Existem na base?	Colunas
1. Como evoluiu o número de turmas entre 2022 e 2026?	Identificação da turma + período	Sim	id_turma, data_inicio (e o semestre do arquivo)
2. Quais escolas e cursos têm mais matrículas?	Escola, curso e matrículas	Sim	escola, curso, matriculas_turma
3. Qual o preenchimento das vagas por modalidade e turno?	Vagas, matrículas, modalidade e turno	Sim	qtde_vagas, matriculas_turma, modalidade, turno

4. Qual a proporção de matrículas aptas por categoria ou curso?	Matrículas aptas, matrículas e categoria	Parcialmente	matriculas_aptas, matriculas_turma, categoria (faltam valores nas turmas não iniciadas)
5. Qual a taxa de evasão dos alunos?	Matrículas que abandonaram o curso	Não	—
6. Qual o perfil dos alunos?	Dados individuais dos estudantes	Não	—

6. Evidências

Evidência	Imagem ou registro
Página da base no portal (título, fonte, período e licença)	

Arquivo aberto no Colab: df.head()

```
#Abrindo o arquivo
df = pd.read_csv("turmasefg_202601.csv", sep=";")

print(df.head())
```

```
   id_turma                      turma                escola  \
0      8877        QP-JLB-ACCN-I1-2026  JOSÉ LUIZ BITTENCOURT
1      8874         QP-JLB-BED-I1-2026  JOSÉ LUIZ BITTENCOURT
2      8661  CP-PAURENAT-PCTOFF-N4-2026  PAULO RENATO DE SOUZA
3      8660         CP-JLB-EXB-M1-2026  JOSÉ LUIZ BITTENCOURT
4      8659       CP-JLB-PLTDR-M2-2026  JOSÉ LUIZ BITTENCOURT

                                      projeto     categoria  \
0                           JORNADA PARA O FUTURO  Qualificação
1                           JORNADA PARA O FUTURO  Qualificação
2  01 - EFGS - ESCOLAS DO FUTURO DO ESTADO DE GOIÁS   Capacitação
3  01 - EFGS - ESCOLAS DO FUTURO DO ESTADO DE GOIÁS   Capacitação
4  01 - EFGS - ESCOLAS DO FUTURO DO ESTADO DE GOIÁS   Capacitação

                                          curso  modalidade  qtde_vagas  \
0  ASSISTENTE EM CIBERSEGURANÇA E COMPUTAÇÃO EM N...  PRESENCIAL           8
1                             DESENVOLVEDOR BACK-END  PRESENCIAL          11
2                                     PACOTE OFFICE  PRESENCIAL          30
3                                       EXCEL BÁSICO  PRESENCIAL          26
4                          PILOTAGEM DE DRONE (VANT)  PRESENCIAL          24

     turno data_inicio    data_fim  status_turma carga_horaria  \
0  INTEGRAL  2026-01-20           -  Não Iniciado            70
1  INTEGRAL  2026-01-20           -  Não Iniciado            88
2   NOTURNO  2026-06-29  2026-07-10     Concluído            20
3  MATUTINO  2026-06-29  2026-07-10     Concluído            18
4  MATUTINO  2026-06-29  2026-07-10     Concluído            16

   matriculas_turma matriculas_aptas
0                 8                -
1                11                -
2                30               14
3                26               13
4                24               12
```

Dimensão: dados.shape

```
#Quantas linhas e quantas colunas existem na sua base
print(df.shape)
```

```
(601, 15)
```

Informações gerais: df.info()

```
#resumo das informações base de dados
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 601 entries, 0 to 600
Data columns (total 15 columns):
 #   Column            Non-Null Count  Dtype 
---  ------            --------------  ----- 
 0   id_turma          601 non-null    int64 
 1   turma             601 non-null    object
 2   escola            601 non-null    object
 3   projeto           601 non-null    object
 4   categoria         601 non-null    object
 5   curso             601 non-null    object
 6   modalidade        601 non-null    object
 7   qtde_vagas        601 non-null    int64 
 8   turno             601 non-null    object
 9   data_inicio       601 non-null    object
 10  data_fim          601 non-null    object
 11  status_turma      601 non-null    object
 12  carga_horaria     601 non-null    object
 13  matriculas_turma  601 non-null    int64 
 14  matriculas_aptas  601 non-null    object
dtypes: int64(3), object(12)
memory usage: 70.6+ KB
```

Valores ausentes: df.isnull().sum()

```
#Contar quantos valores ausentes existem em cada coluna da base de dados.
df.isnull().sum()
```

	0
id_turma	0
turma	0
escola	0
projeto	0
categoria	0
curso	0
modalidade	0
qtde_vagas	0
turno	0
data_inicio	0
data_fim	0
status_turma	0
carga_horaria	0
matriculas_turma	0
matriculas_aptas	0

dtype: int64

Duplicidades: df.duplicated().sum()

```
#Contar quantas linhas duplicadas existem na base de dados
df.duplicated().sum()
```

```
np.int64(0)
```

Estatísticas: df.describe()

```
#Resumo estatístico da sua base de dados
df.describe()
```

	id_turma	qtde_vagas	matriculas_turma
count	601.000000	601.000000	601.000000
mean	8185.803661	25.019967	23.637271
std	461.050035	13.181790	13.075354
min	6746.000000	0.000000	0.000000
25%	8168.000000	14.000000	13.000000
50%	8321.000000	27.000000	25.000000
75%	8475.000000	30.000000	30.000000
max	8877.000000	100.000000	100.000000